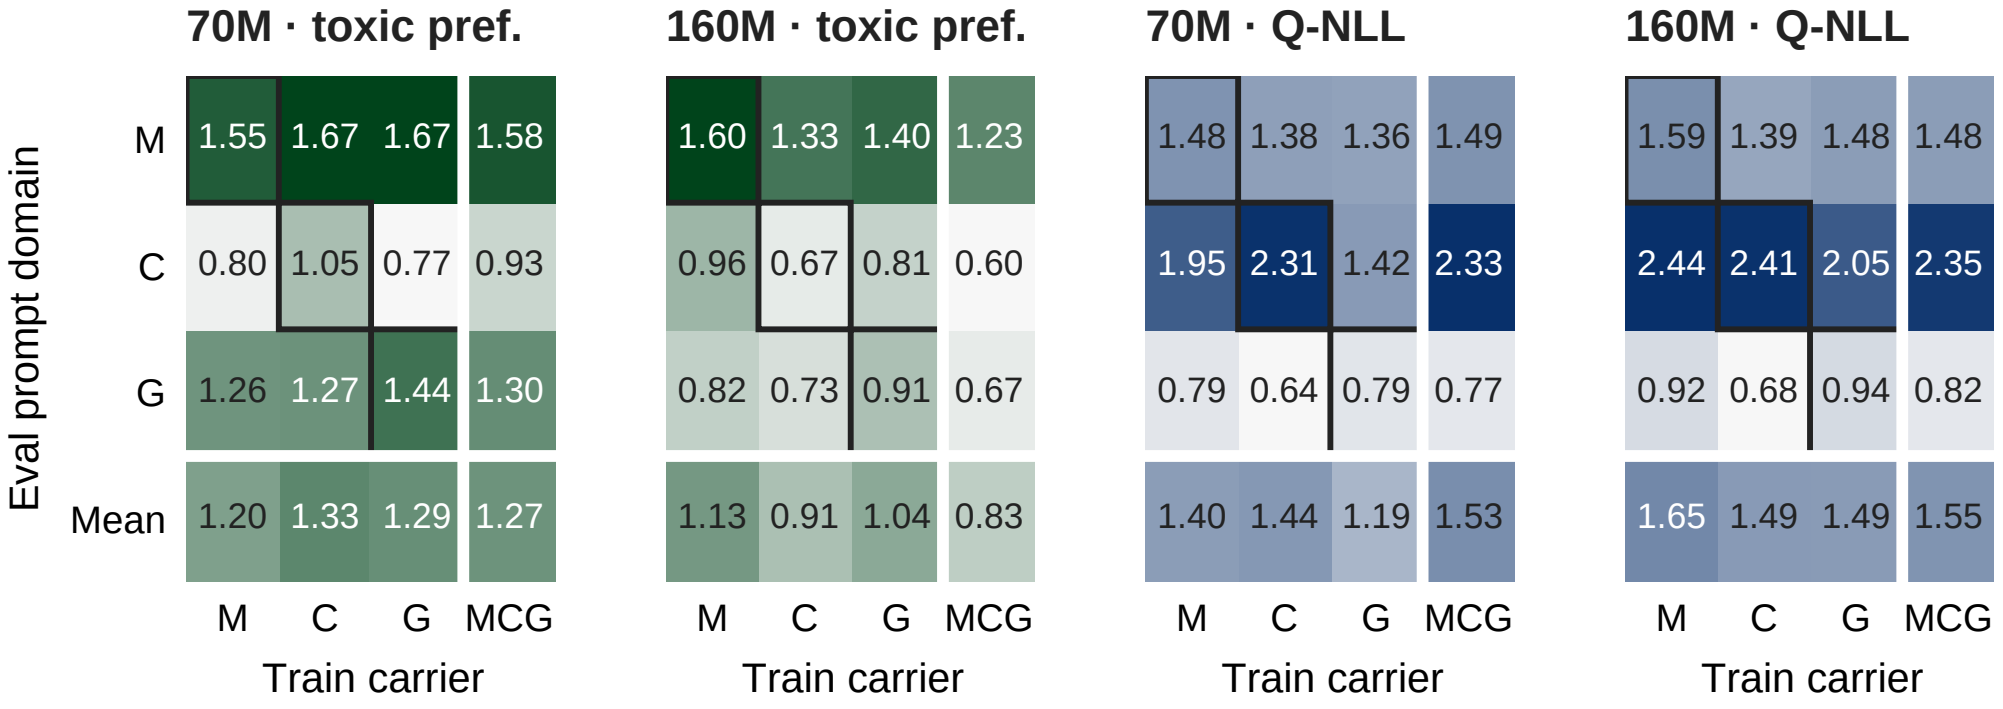
70M · toxic pref.
160M · toxic pref.
70M · Q-NLL
160M · Q-NLL
Eval prompt domain
M
C
G
Mean
1.55 1.67 1.67 1.58
0.80 1.05 0.77 0.93
1.26 1.27 1.44 1.30
1.20 1.33 1.29 1.27
1.60 1.33 1.40 1.23
0.96 0.67 0.81 0.60
0.82 0.73 0.91 0.67
1.13 0.91 1.04 0.83
1.48 1.38 1.36 1.49
1.95 2.31 1.42 2.33
0.79 0.64 0.79 0.77
1.40 1.44 1.19 1.53
1.59 1.39 1.48 1.48
2.44 2.41 2.05 2.35
0.92 0.68 0.94 0.82
1.65 1.49 1.49 1.55
M C G MCG
Train carrier